

1. Poiščite globalno poravnavo zaporedij  $s_1 = \text{ATTCG}$ ,  $s_2 = \text{GGAGT}$ ,  $s_3 = \text{TGACG}$  in  $s_4 = \text{GAACT}$  z uporabo

- (a) algoritma za progresivno poravnavo
- (b) 2-aproksimacijskega algoritma

Za razdaljo med dvema zaporedjema uporabite Needleman-Wunschev algoritem z nagrado 0 za ujemanje in kaznijo za zamenjavo, vstavljanje in brisanje enako 1.

### a) Progresivna poravnava

1. Matrica razdalj
2. Drevo UPGMA
3. MSA

- $\binom{k}{2}$  parov zaporedij
- $k$  zaporedij

#### 1. Matrica razdalj (več možnih razdalj)


• Razdalja = ocena globalne poravnave (absolutne vrednosti)

	$s_1$	$s_2$	$s_3$	$s_4$
$s_1$	0	5	3	4
$s_2$		0	3	2
$s_3$			0	3
$s_4$				0

Poravnave so bile že ustvarjene, drugače moras vse naredit sam.

#### 2. Drevo UPGMA (več metod: UPGMA, neighbor joining, iz aditivnih matrik)

	$s_1$	$s_2$	$s_3$	$s_4$
$s_1$	0	5	3	4
$s_2$		0	3	2
$s_3$			0	3
$s_4$				0




$$d(C_1, s_1) = \frac{d(s_2, s_1) + d(s_1, s_4)}{|C_1|} = \frac{5+4}{2} = 4.5$$


$d(C_1, s_3) = \text{analogno}$

	$s_1$	$C_1$	$s_3$
$s_1$	0	4.5	3
$C_1$		0	3
$s_3$			0

izbereš enega



= očitno bo  $C_3 = (C_2, C_1) \Rightarrow$



### 3. MSA

- vsaki grupi določimo najboljšo poravnavo zaporedja ene skupine z zaporedjem iz druge skupine (najboljša = najmanjša):

- $C_1$  ima poravnavo  $(s_2, s_4)$
- $C_2$  ima poravnavo  $(s_1, s_3)$
- $C_3$  ima poravnavo  $\min\{C_1, C_2\} = \min\{d(s_2, s_1), d(s_2, s_3), d(s_4, s_1), d(s_4, s_3)\}$   
 $= \min\{5, 3, 4, 3\}$ ; izberemo  $(s_2, s_3)$ , saj se  $s_4$  boljše poravnava z  $s_1$ .

- Začnemo na vrhu s  $C_3 = (s_2, s_3)$  in progresivno dodajamo poravnave.

- $s_4$  dodaš v  $(s_2, s_3)$  glede na to kako se poravnava z  $s_2$
- $s_1$  dodaš v  $(s_4, s_2, s_3)$  glede na to kako se poravnava z  $s_3$

$s_2$  | G G A - G T  
 $s_3$  | T G A C G -

→  $s_2$  | G G A G T  
 $s_4$  | G A A C T

$s_4$  | G A A - C T  
 $s_2$  | G G A - G T  
 $s_3$  | T G A C G -

→  $s_1$  | A T T C G  
 $s_3$  | T G A C G

$s_4$  | G A A - C T  
 $s_2$  | G G A - G T  
 $s_3$  | T G A C G -  
 $s_1$  | A T T C G -

## b) 2-aproksimacijski algoritem

- 1. korak je enak kot pri (a); 2. korak ni potreben - nadomestimo ga z naslednjim algoritmom:
- Vrednost poravnave je enaka vsoti vrednosti poravnav vseh  $\binom{k}{2}$  parov zaporedij, induciranih s poravnavo  $k$  zaporedij.
- Predp., da iščemo čim manjše vrednosti
- Vsota parov poravnav  $k$ -zaporedij bo kvečjemu za faktor  $2^{-\frac{k}{2}}$  večja od optimalne vsote parov.

	S <sub>1</sub>	S <sub>2</sub>	S <sub>3</sub>	S <sub>4</sub>	
S <sub>1</sub>	0	5	3	4	= 12
S <sub>2</sub>	5	0	3	2	= 10
S <sub>3</sub>	3	3	0	3	= 9
S <sub>4</sub>	4	2	3	0	= 9

seštejemo vrstice ...

MSA:

S <sub>1</sub>	A	T	T	-	C	G	-
S <sub>2</sub>	G	G	A	-	-	G	T
S <sub>3</sub>	T	G	A	-	C	G	-
S <sub>4</sub>	-	G	A	A	C	T	-

Izberemo enega izmed teh dveh najmanjših. Izberimo npr. S<sub>3</sub>.

- Poravnava po vrsti (S<sub>1</sub>, S<sub>3</sub>), (S<sub>1</sub>, S<sub>2</sub>, S<sub>3</sub>), (S<sub>1</sub>, S<sub>2</sub>, S<sub>4</sub>, S<sub>3</sub>). glede na (S<sub>1</sub>, S<sub>3</sub>), (S<sub>2</sub>, S<sub>3</sub>) in (S<sub>4</sub>, S<sub>3</sub>).

S <sub>1</sub>	A	T	T	C	G
S <sub>3</sub>	T	G	A	C	G

S <sub>2</sub>	G	G	A	-	G	T
S <sub>3</sub>	T	G	A	C	G	-

S <sub>3</sub>	T	G	A	-	C	G
S <sub>4</sub>	-	G	A	A	C	T

Vrednost poravnave:

$$v(A) := \sum_{i < j} v_A(s_i, s_j)$$

Iz MSA dobimo Levenshteinovo razdaljo za vsak par:

- $v_A(s_1, s_2) = 5$
- $v_A(s_2, s_3) = 3$
- $v_A(s_3, s_4) = 3$
- $v_A(s_2, s_4) = 5$

S <sub>1</sub>	A	T	T	-	C	G	-
S <sub>2</sub>	G	G	A	-	-	G	T

- $v_A(s_1, s_3) = 3$
- $v_A(s_1, s_4) = 5$

$$v(A) = 5 + 3 + 5 + 3 + 5 + 3 = 24$$

Za optimalno poravnavo  $A^*$  velja:


$$v(A_c) \leq (2 - 2/k) v(A^*)$$

$$v(A_c) / (2 - 2/k) \leq v(A^*)$$

Dobimo jo tako, da iz matrice razdalj odčitamo razdalje med zaporedji; vzamemo manjšo izmed te in one razdalje iz MSA:

$$v(A^*) = 5 + 3 + 4 + 3 + 2 + 3 = 20$$

\*. Kako bi poravnali zaporedja glede na drevo:



- C<sub>1</sub> ima (S<sub>1</sub>, S<sub>2</sub>)
- C<sub>2</sub> ima (S<sub>3</sub>, S<sub>4</sub>)
- C<sub>3</sub> ima (S<sub>5</sub>, S<sub>6</sub>)

- C<sub>4</sub> ima  $\min\{C_2, C_3\} = \min\{d(S_3, S_5), d(S_3, S_6), d(S_4, S_5), d(S_4, S_6)\}$  npr. (S<sub>3</sub>, S<sub>5</sub>)

- C<sub>5</sub> ima  $\min\{C_1, C_4\} = \min\{d(S_1, S_3), d(S_1, S_5), d(S_2, S_3), d(S_2, S_5)\}$  npr. (S<sub>1</sub>, S<sub>5</sub>) par, ki smo ga izbrali za C<sub>4</sub>, ne vsa zaporedja spadaj...

Za poravnavo potrebujemo poravnave zaporedij: (S<sub>1</sub>, S<sub>2</sub>), (S<sub>3</sub>, S<sub>4</sub>), (S<sub>5</sub>, S<sub>6</sub>), (S<sub>3</sub>, S<sub>5</sub>) in (S<sub>1</sub>, S<sub>5</sub>).